

TP Avancé : Agents IA avec Olama

Prompt Chaining, Routing et Orchestration

Djebabla Ammar

December 16, 2025

Contents

1	Objectifs du TP	2
2	Concepts clés	2
2.1	Prompt Chaining	2
2.2	Evaluator	2
2.3	Routing	2
2.4	Orchestration	2
2.5	Evaluation	2
3	Exemple de Lab Guidé avec Olama	3
3.1	1. Prompt Chaining Avancé	3
3.2	2. Routing Dynamique	3
3.3	3. Evaluator Avancé	3
4	Illustration Schématique	4
5	Exercices et Challenges	4

1 Objectifs du TP

Dans ce TP, vous allez apprendre à :

- Comprendre le **Prompt Chaining** et comment enchaîner plusieurs requêtes à un LLM.
- Utiliser des **Evaluators** pour évaluer automatiquement la qualité des réponses.
- Mettre en place un **Routing** dynamique pour décider quel agent ou modèle traiter la requête.
- Concevoir l'**Orchestration** des agents pour des tâches complexes.
- Réaliser une **Evaluation** quantitative et qualitative des résultats.

2 Concepts clés

2.1 Prompt Chaining

Définition : Enchaîner plusieurs prompts où chaque sortie devient l'entrée du suivant. **Avantages** : Permet de décomposer une tâche complexe en étapes simples, améliore la précision et la cohérence.

Exemple : Résumer un texte → Traduire → Reformuler → Simplifier.

2.2 Evaluator

Définition : Module qui évalue automatiquement la qualité d'une réponse selon des critères précis. **Exemple** : Calculer un score de similarité entre un texte généré et le texte original.

2.3 Routing

Définition : Choisir dynamiquement quel agent ou modèle doit traiter la requête. **Exemple** : Questions techniques → CodeLLM, Questions générales → ChatLLM.

2.4 Orchestration

Définition : Coordination de plusieurs agents ou prompts pour accomplir une tâche complexe. **Exemple** :

- Agent A : collecte des informations
- Agent B : analyse et synthétise
- Agent C : génère le rapport final

2.5 Evaluation

Définition : Analyse des performances de l'agent ou du workflow selon plusieurs critères (cohérence, pertinence, lisibilité). **Exemple** : Comparer le texte final avec des références et calculer un score global.

3 Exemple de Lab Guidé avec Olama

3.1 1. Prompt Chaining Avancé

```
from olama import Client

client = Client(api_key="VOTRE_CLE_API")

# tape 1 : Résumer un texte
texte = "Les agents IA peuvent automatiser des tâches complexes..."
res1 = client.generate(f"Résume ce texte : '{texte}'")

# tape 2 : Traduire en anglais
res2 = client.generate(f"Traduire en anglais : '{res1.text}'")

# tape 3 : Reformuler dans un style formel
res3 = client.generate(f"Reformule de manière formelle : '{res2.text}'")

print("Texte final :", res3.text)
```

3.2 2. Routing Dynamique

```
def route_request(question):
    if "python" in question.lower() or "code" in question.lower():
        return "CodeLLM"
    elif "texte" in question.lower() or "résumé" in question.lower():
        return "ChatLLM"
    else:
        return "GeneralLLM"

question = "Crée une fonction Python pour trier une liste"
agent = route_request(question)
response = client.generate(prompt=question, model=agent)
print(response.text)
```


3.3 3. Evaluator Avancé

```
from difflib import SequenceMatcher

def evaluate(reference, generated):
    score = SequenceMatcher(None, reference, generated).ratio()
    return round(score, 2)

reference = "Les agents IA automatisent des tâches complexes de manière autonome."
score = evaluate(reference, res3.text)
print("Score de qualité :", score)
```

4 Illustration Schématique



5 Exercices et Challenges

1. Créez un **prompt chaining** avec quatre étapes : résumé, traduction, reformulation et simplification.
2. Implémentez un **evaluator multi-critères** prenant en compte :
 - Cohérence
 - Lisibilité
 - Fidélité au texte original
3. Ajoutez un **routing dynamique** selon le type de requête et le style demandé.
4. Orchestration : créez un workflow où deux agents travaillent en parallèle et combinent leurs résultats.
5. Challenge avancé : implémentez un mini système de scoring qui choisit automatiquement le meilleur texte parmi plusieurs outputs générés.
6. Challenge final : combinez tous les concepts pour créer un **assistant IA multi-agent** capable de répondre à n'importe quelle question, générer plusieurs reformulations, évaluer et sélectionner la meilleure.